

코드 분석보고서

- Recommender -

추천 시스템 기반 영화 추천:

MovieLens 데이터셋을 활용한 Content-Based 및
Collaborative Filtering 추천 시스템 구축

1. 서론

1.1 분석 목적

본 실습은 MovieLens 영화 평점 데이터셋을 활용하여 추천 시스템(Recommender System)을 구축하고 비교 분석하는 것을 목적으로 한다. 구체적으로 Content-Based Filtering과 User-based/Item-based Collaborative Filtering을 각각 구현하고, 두 접근법의 추천 결과와 성능을 비교한다. 또한 Utility Matrix의 희소성(Sparsity) 문제, Cold-Start 문제 등 추천 시스템의 한계를 직접 체험하고 분석한다.

1.2 추천 시스템 개요

추천 시스템은 사용자가 관심을 가질 만한 아이템을 자동으로 필터링하여 제시하는 시스템으로, Netflix, Amazon, Pandora 등 다양한 플랫폼에서 활용된다. 정보 과부하(Information Overload) 문제를 해결하고 개인화된 서비스를 제공하는 핵심 기술이다. 크게 두 가지 접근법이 있다.

- Content-Based Filtering: 아이템의 속성을 기반으로 사용자가 좋아한 아이템과 유사한 아이템을 추천
- Collaborative Filtering: 사용자의 평점 패턴을 기반으로 유사한 사용자 혹은 아이템을 찾아 추천

두 방법은 각각 고유한 장단점을 가지며, 이를 결합한 Hybrid 방법이 많이 활용된다.

2. 데이터 탐색적 분석 (EDA)

2.1 데이터 셋 기본 정보

본 실습에서는 GroupLens Research의 MovieLens Latest Small 데이터셋을 사용하였다. 데이터는 ratings.csv, movies.csv, tags.csv 세 파일로 구성되며 결측치는 존재하지 않는다. 또한 평점은 0.5~5.0점 범위에서 0.5 단위로 부여되며 전체 평균은 3.50점이다.

항목	ratings.csv	movies.csv	tags.csv
행 수	100,836	9,742	3,683
주요 컬럼	userId, movieId, rating, timestamp	movieId, title, genres	userId, movieId, tag, timestamp
결측치	없음	없음	없음

2.2 평점 분포




그림1. 평점 분포 막대 그래프

평점 분포를 분석한 결과, 4.0점이 가장 많이 부여되었으며 전반적으로 양의 편향(positive)을 보인다. 즉, 사용자들은 낮은 평점보다 높은 평점을 더 많이 부여하는 경향이 있음을 알 수 있다.

2.3 사용자/영화별 평점 수




그림2. 사용자별 평점 분포 막대 그래프




그림3. 영화별 평점 분포 막대 그래프

사용자별 및 영화별 평점 수 분포는 모두 Long-tail 분포를 따른다. 소수의 헤비유저와 인기 영화에 평점이 집중되어 있으며, 대다수의 사용자와 영화는 평점 수가 매우 적다.

- 사용자별 평점 수: 평균 165건, 중앙값 70건으로 2배 이상의 차이가 난다. 이는 소수의 헤비유저가 평균을 끌어올리고 있음을 알 수 있다.
- 영화별 평점 수: 평균 10건, 중앙값 3건으로 격차가 매우 크다. 이는 대부분의 영화는 평점이 거의 없고 소수 인기 영화에 평점이 집중됨을 보여준다.

2.4 Utility Matrix 분석

사용자×영화 Utility Matrix를 생성하여 희소성(Sparsity)을 계산한다.

항목	값
사용자 수	610 명
영화 수	9,724 편
평점 수	100,836 건
Matrix 크기	$610 \times 9,724 = 5,931,640$ 셀
Sparsity	$1 - (100,836) / (610 \times 9,724) = 98.3\%$




그림4. Utility matrix

Sparsity가 98.30%으로 전체 가능한 평점의 단 1.70%만 관측되었다. 이는 Collaborative Filtering의 성능을 제한하는 핵심 Sparsity 문제이다. 메모리 효율을 위해 scipy.sparse의 csr_matrix를 활용하여 희소 행렬로 저장하고자 한다.

2.5 장르별 분포 분석




그림5. 장르별 평균 평점과 영화 수 분석 결과

Film-Noir(3.92), War(3.81), Documentary(3.80) 장르가 평균 평점이 높지만 영화 수는 적다. 반면 Drama(4,361편), Comedy(3,756편)는 영화 수가 가장 많아 플랫폼의 핵심 콘텐츠이라고 할 수 있다. Horror는 평균 평점(3.26)이 가장 낮다. 이처럼 평점이 높은 장르가 반드시 영화 수가 많은 것은 아니며, 평점은 장르의 특성과 평가자 집단의 성향에 따라 달라진다.

2.6 연도별 평점 분포 분석




그림6. 연도별 평점 분포 분석 결과

평점 수는 2000년에 최고치(약 10,000건)를 기록한 후 감소하였다가 2015~2018년에 다시 증가하는 양상을 보인다. 평균 평점은 3.4~3.9점 사이에서 연도별로 등락을 반복하며 뚜렷한 상승 또는 하락 추세는 나타나지 않는다. 전반적으로 평점 수와 평균 평점 간의 뚜렷한 상관관계는 보이지 않는다. 연도별 분석을 통해 추천 시스템의 추가적인 한계를 확인하고자 한다. 본 실습에서는 최신 평점과 오래된 평점을 동일하게 취급하였으나, 실제로는 시간이 지남에 따라 사용자의 취향이 변할 수 있다.

3. Content-Based Filtering

3.1 Content Profile 구축

영화의 장르(genres) 정보와 tags.csv의 태그 정보를 결합하여 각 영화의 Content Profile을 구축하였다. 장르는 '|' 구분자를 공백으로 변환하고, 태그는 영화별로 하나의 문자열로 결합하였다.

- Content Profile = 장르(2배 가중) + 태그
- 장르를 2배 반복: 장르는 객관적 정보, 태그는 주관적 정보이므로 장르에 더 높은 가중치 부여
- TF-IDF 벡터화 적용 (min_df=2, max_features=5000, ngram_range=(1,2))
- Content Profile이 있는 영화: 9,709편 / 태그가 있는 영화: 1,572편

TF-IDF 행렬 크기: $(9,742 \times 1,583) \rightarrow$ 영화 수 $\times$ 단어 수

3.2 영화 간 코사인 유사도 계산

TF-IDF 행렬에 linear_kernel을 적용하여 영화 간 코사인 유사도를 계산했다. 코사인 유사도는 두 벡터 간 각도의 코사인값으로, 0에 가까울수록 비유사, 1에 가까울수록 유사함을 의미한다. 대각선

값(자기 자신과의 유사도)은 모두 1.0으로 확인되어 계산이 정확함을 검증했다.

3.3 영화 기반 추천 결과 (Item Profiles)

Toy Story (1995) (장르: Adventure|Animation|Children|Comedy|Fantasy)를 기준 영화로 선택하여 유사 영화 Top 10을 추천한 결과이다.

[표1] Toy Story(1995) Content-Based (Item profiles) 추천 Top 10

순위	영화명	장르	유사도
1	Bug's Life, A (1998)	Adventure Animation Children Comedy	0.798
2	Antz (1998)	Adventure Animation Children Comedy Fantasy	0.783
3	Adventures of Rocky and Bullwinkle, The (2000)	Adventure Animation Children Comedy Fantasy	0.783
4	Emperor's New Groove, The (2000)	Adventure Animation Children Comedy Fantasy	0.783
5	Monsters, Inc. (2001)	Adventure Animation Children Comedy Fantasy	0.783
6	Wild, The (2006)	Adventure Animation Children Comedy Fantasy	0.783
7	Shrek the Third (2007)	Adventure Animation Children Comedy Fantasy	0.783
8	Tale of Despereaux, The (2008)	Adventure Animation Children Comedy Fantasy	0.783
9	Asterix and the Vikings (2006)	Adventure Animation Children Comedy Fantasy	0.783
10	Turbo (2013)	Adventure Animation Children Comedy Fantasy	0.783

추천된 10편 모두 Adventure, Animation, Children, Comedy 장르를 포함하여 기준 영화와 매우 높은 장르 일치성을 보였다. 추천된 영화들(Antz, Monsters Inc., Shrek 등)은 실제로 Toy Story와 유사한 애니메이션 계열 영화로, 추천 결과가 직관적으로 타당하다. 그러나 추천 결과가 Animation/Children 계열에 완전히 편중되어 있어 Overspecialization 문제가 존재함을 알 수 있다.

3.4 User Profile 기반 추천 결과 (User Profiles)

[표2] User 1 Content-Based (User profiles) 추천 Top 10

순위	영화명	장르	CB 점수
1	Twelve Tasks of Asterix, The (1976)	Action Adventure Animation Children Comedy Fantasy	0.5851
2	TMNT (Teenage Mutant Ninja Turtles) (2007)	Action Adventure Animation Children Comedy Fantasy	0.5851
3	Ratchet & Clank (2016)	Action Adventure Animation Children Comedy Sci-Fi	0.5790
4	Chicken Little (2005)	Action Adventure Animation Children Comedy Sci-Fi	0.5790
5	G.I. Joe: The Movie (1987)	Action Adventure Animation Children Fantasy Sci-Fi	0.5607
6	Batman/Superman Movie, The (1998)	Action Adventure Animation Children Fantasy Sci-Fi	0.5607

7	The Great Train Robbery (1978)	Action Adventure Comedy Crime Drama	0.5524
8	Flashback (1990)	Action Adventure Comedy Crime Drama	0.5524
9	Maximum Ride (2016)	Action Adventure Comedy Fantasy Sci-Fi Thriller	0.5511
10	Meet the Robinsons (2007)	Action Adventure Animation Children Comedy Sci-Fi	0.5500

User 1의 4.0점 이상 고평점 영화 200편을 기반으로 User Profile을 구축하여 추천한 결과, 10편 모두 Action, Adventure, Comedy 장르가 포함되어 있으며, User 1의 고평점 영화 장르 분포가 User Profile에 그대로 반영되었다. Overspecialization 비율이 100%로 확인되어, User 1이 좋아하는 장르 범위 밖의 영화는 단 하나도 추천되지 않았다. 이는 Content-Based Filtering의 다양성 부족이라는 한계를 명확히 보여주는 결과이다.

3.5 Content-Based Filtering 장점과 한계

장점:

- Cold-Start 문제 없음: 새 사용자가 단 1편만 평가해도 즉시 추천 가능, 다른 사용자 데이터 불필요
- 새롭고 비인기 아이템 추천 가능: 평점 수가 적은 영화도 장르+태그 유사도가 높으면 추천 목록에 포함됨
- 추천 이유 설명 가능: cosine_similarity 점수와 장르 정보로 추천한 이유 확인 가능

한계:

- Overspecialization (과특화): 실습 결과에서 Overspecialization 비율 100% 확인 → User 1이 본 적 없는 장르는 단 하나도 추천되지 않음
- 새 사용자 프로필 구축 어려움: 평점이 아예 없는 사용자는 User Profile 자체를 만들 수 없음

4. Collaborative Filtering

4.1 데이터 분리

사용자별로 80%는 학습, 20%는 테스트 데이터로 분리했다. 평점이 5개 미만인 사용자는 전부 학습에 사용하여 Cold-Start 문제를 방지한다.

- 학습 데이터: 80,419건 (79.8%)
- 테스트 데이터: 20,417건 (20.2%)
- 학습 Utility Matrix 크기: $610 \times 8,965$

4.2 유사도 계산

- User-based CF

- 코사인 유사도 vs 피어슨 상관계수

[표3] User 1 기준 유사 사용자 Top 5 비교

순위	코사인 유사도		피어슨 상관계수	
	User ID	유사도	User ID	유사도
1	368	0.3019	206	0.1407
2	266	0.2971	75	0.1057
3	57	0.2966	198	0.0952
4	313	0.2900	201	0.0947
5	330	0.2872	577	0.0913

두 방법의 상위 유사 사용자가 완전히 다르게 나타났다. 코사인 유사도는 벡터들 간의 각도를 기준으로 유사 사용자를 찾는 반면, 피어슨 상관계수는 평점 편향을 제거하여 엄격한 평가자와 후한 평가자 간의 스케일 차이를 보정한다. 피어슨의 유사도 값(최대 0.1407)이 코사인(최대 0.3019)보다 낮게 나타난 것은, 편향 제거 후 실질적인 취향 일치도가 낮음을 의미할 것이다.

- Item-based CF

[표4] Toy Story (1995) Item-based CF 유사 영화 Top 10

순위	영화명	장르	유사도
1	Star Wars: Episode IV - A New Hope (1977)	Action Adventure Sci-Fi	0.4478
2	Aladdin (1992)	Adventure Animation Children Comedy Musical	0.4326
3	Back to the Future (1985)	Adventure Comedy Sci-Fi	0.4231
4	Independence Day (1996)	Action Adventure Sci-Fi Thriller	0.4297
5	Willy Wonka & the Chocolate Factory (1971)	Children Comedy Fantasy Musical	0.4156
6	Star Wars: Episode V - The Empire Strikes Back (1980)	Action Adventure Sci-Fi	0.4135
7	Star Wars: Episode VI - Return of the Jedi (1983)	Action Adventure Sci-Fi	0.4121
8	Indiana Jones and the Last Crusade (1989)	Action Adventure	0.4127

9	Wizard of Oz, The (1939)	Adventure Children Fantasy Musical	0.4092
10	Raiders of the Lost Ark (1981)	Action Adventure	0.3977

Content-Based Filtering이 Animation/Children 계열에 집중된 것과 달리, Item-based CF는 Star Wars 시리즈, Indiana Jones, Back to the Future 등 Action/Adventure/Sci-Fi 계열 영화를 주로 추천하였다. 이는 실제 사용자들이 Toy Story를 좋아한 경우 이 영화들도 함께 높게 평가하는 경향이 있음을 반영한 것으로, 장르 정보만이 아닌 사용자 평점 패턴을 기반으로 더 다양한 추천이 가능함을 보여준다.

4.3 KNN 기반 평점 예측

사용자의 평균 평점(μ_u)에, 유사 사용자들의 평점 편차를 유사도로 가중 평균한 값을 더하는 방식이다. 이를 통해 각 사용자의 평점 스케일 차이(Rating Bias)를 보정한다.

- 검증: User 1의 Toy Story (movieId=1) 예측 평점 4.71점, 실제 평점 4.0점

4.4 K값 변화에 따른 성능 비교

- RMSE (Root Mean Squared Error)

- $\sqrt{\text{mean}((\text{실제 평점} - \text{예측 평점})^2)}$
- 오차를 제곱하기 때문에 큰 오차에 더 민감함

- MAE (Mean Absolute Error)

- 실제 평점과 예측 평점의 차이의 절댓값 평균
- 직관적으로 해석하기 쉬움

[표5] K값에 따른 성능 비교

K 값	RMSE	MAE
5	0.9132	0.6931
10	0.8956	0.6795
20	0.8965	0.6813
50	0.9035	0.6869




그림7. K값에 따른 성능 변화 시각화

K=10에서 RMSE=0.8956, MAE=0.6795으로 최적 성능을 보였다. K가 작을수록 소수의 이웃에 의존하여 노이즈에 민감하고, K가 클수록 관련성이 낮은 사용자까지 포함되어 성능이 저하된다. 따라서 적절한 K값 선택이 중요하며, 본 실습에서는 K=10이 최적이다.

4.5 성능 평가 Baseline VS Collaborative Filtering

[표6] Baseline vs User-based CF 성능 비교

방법	RMSE	MAE
Baseline (전체 평균)	1.0598	0.8382
User-based CF (K=10)	0.8956	0.6795
개선량	-0.1642	-0.1586

User-based CF(K=10)는 전체 평균으로 예측하는 Baseline 대비 RMSE를 0.1642, MAE를 0.1586 개선했다. 단순 평균 예측보다 유사 사용자의 평점 패턴을 반영한 CF가 더 정확한 예측을 수행함을 확인할 수 있다.

4.6 Serendipity 분석




그림8. 두 방법의 Serendipity 분석 비교

CB와 CF의 장르 다양성을 비교하여 어떤 방법이 더 다양하고 예상치 못한 추천을 하는지 분석하기 위해 Serendipity를 보고자 한다. CB와 CF 모두 고유 장르 수는 10개로 동일하나, 장르 구성이 완전히 다르다. CB는 Action, Adventure, Animation, Children 계열에 편중된 반면, CF는 Drama, Crime, Mystery, IMAX 등 더 다양한 장르가 고르게 분포되어 있다. 이는 CB보다 CF가 사용자가 예상치 못한 장르를 추천하는 Serendipity 측면에서 더 우수하다고 볼 수 있다.

5. 성능 평가 및 비교

5.1 Surprise 라이브러리를 활용한 알고리즘 비교

Surprise 라이브러리를 활용하여 SVD, SVD++, NMF, KNN 기반 알고리즘을 비교하였다.




그림8. 알고리즘별 성능 비교

SVD++ (RMSE 0.8803)가 가장 우수한 성능을 보였으며, SVD와 함께 Matrix Factorization 계열이 KNN 기반 CF보다 월등히 낮은 오차를 기록하였다. 이는 잠재 요인(Latent Factor) 분해를 통해 Sparsity 문제를 효과적으로 처리하기 때문이다. 직접 구현한 User-based CF(RMSE 0.8956)는 Surprise의 KNN보다 우수한 성능을 보였으며, 모든 방법이 Baseline(1.0598) 대비 개선되었다.

5.2 Hybrid 추천 시스템 구현

Content-Based(CB)와 Matrix Factorization(SVD)을 가중 결합한 Hybrid 추천 시스템을 구현하였다. 최종 점수는 $\alpha \times \text{CB점수} + (1-\alpha) \times \text{SVD점수}$ 로 계산되며, $\alpha=0.3$ (CB 30% + SVD 70%)을 기본값으로 사용하였다.

[표7] User 1 Hybrid 추천 결과 ($\alpha=0.3$)

순위	영화명	장르	Hybrid 점수
1	Lord of the Rings: The Return of the King (2003)	Action Adventure Drama Fantasy	0.862
2	Wallace & Gromit: The Wrong Trousers (1993)	Animation Children Comedy Crime	0.859
3	Fifth Element, The (1997)	Action Adventure Comedy Sci-Fi	0.846
4	Finding Nemo (2003)	Adventure Animation Children Comedy	0.843
5	Mary Poppins (1964)	Children Comedy Fantasy Musical	0.830
6	Breakfast Club, The (1985)	Comedy Drama	0.829
7	Little Miss Sunshine (2006)	Adventure Comedy Drama	0.825
8	Deadpool (2016)	Action Adventure Comedy Sci-Fi	0.816
9	Last Samurai, The (2003)	Action Adventure Drama War	0.814
10	Casino Royale (2006)	Action Adventure Thriller	0.814

$\alpha=0$ (SVD만)에서는 Shawshank Redemption, Godfather 등 명작 위주로 추천되었고, $\alpha=1$ (CB만)에서는 Action/Adventure/Comedy 계열에 편중되었다. $\alpha=0.3$ 의 Hybrid에서는 두 방법의 강점이 균형있게 결합되어 장르 다양성과 예측 정확도를 동시에 확보하였다. Radar Chart에서도 Hybrid가 Cold-Start, Sparsity 처리, Serendipity, 정확도 등 전반적인 관점에서 가장 균형잡힌 성능을 보임을 확인하였다.

6. 결론 및 논의

6.1 분석 요약

본 실습에서는 MovieLens 데이터셋(610명, 9,724편, 100,836건)을 활용하여 Content-Based Filtering, Collaborative Filtering, Matrix Factorization, Hybrid 추천 시스템을 구축하고 비교 분석하였다. Content-Based는 Overspecialization 비율 100%로 다양성 부족이 확인되었고, User-based CF(K=10)는 Baseline 대비 RMSE를 0.1642 개선하였다. SVD++가 RMSE 0.8803으로 가장 우수한 성능을 보였으며, Hybrid($\alpha=0.3$)가 장르 다양성과 예측 정확도를 동시에 확보하였다.

6.2 한계점

- Cold-Start 문제: CF와 SVD 계열은 평점 데이터가 없는 새 사용자나 신규 영화에 대해 추천이 불가능하다. 실습에서도 평점이 없는 사용자의 User Profile을 생성할 수 없음을 확인했다.
- Sparsity 문제: Utility Matrix의 98.30%가 비어 있어 KNN 기반 유사도 계산의 신뢰도가 낮다. 공통 평점이 적을수록 유사도 계산이 부정확해지며 추천 품질이 저하된다.
- Content Profile의 한계: 장르와 태그만 활용하여 배우, 감독, 분위기 등 중요한 특성이 반영되지 않았다.

6.3 향후 개선 방향

- Matrix Factorization 고도화: SVD++ 외에 ALS(Alternating Least Squares) 등을 적용하여 대규모 데이터에서의 Sparsity 문제를 효과적으로 해결할 수 있다.
- Hybrid 방법 확장: CB와 CF의 결합 외에 인구통계학적 정보나 시간 정보를 추가하여 Cold-Start 문제를 보완할 수 있다.
- 딥러닝 기반 추천: Neural Collaborative Filtering(NCF), BERT4Rec 등으로 비선형 관계를 포착하고 추천 성능을 향상시킬 수 있다.
- 추가 특성 활용: 영화 줄거리, 감독, 배우 정보 및 사용자 행동 시간 정보를 활용하여 더 풍부한 Content Profile을 구성할 수 있다.