

실습과제 분석보고서

- 실습 1_LDA -

LDA 기반 감성별 토픽 분석 과제:
COVID-19 트윗 데이터셋을 활용한 감성별 토픽 모델링

과목명	데이터어널리틱스
과목 주제	감성 레이블별 LDA 토픽 모델링 및 비교 분석
담당교수	김선혜
학과	산업시스템공학과
학번	2022112370
이름	이채연
제출일	2026.04.07

1. 서론

1.1 분석 배경 및 목적

COVID-19 팬데믹으로 인한 일상 및 소비 패턴의 급격한 변화가 실시간으로 투영된 소셜 미디어(Twitter) 데이터를 활용하여 감성 분석(Sentiment Analysis)과 토픽 모델링(Topic Modeling)을 결합한 텍스트 분석을 수행한다.

구체적으로, 5개 감성 레이블(Extremely Positive, Positive, Neutral, Negative, Extremely Negative)을 3개 그룹(긍정/중립/부정)으로 병합한 뒤, 각 감성 그룹에 독립적으로 LDA(Latent Dirichlet Allocation) 토픽 모델을 적용하여 그룹 간 주요 주제를 비교 분석한다.

1.2 LDA(Latent Dirichlet Allocation) 모델 개요

LDA는 문서의 잠재적 토픽 구조를 발견하는 확률적 생성 모델로, 토픽별 단어 분포를 직접 해석할 수 있어 해석 가능성이 높고, 대규모 텍스트 데이터에서 잠재적 주제 구조를 효과적으로 발견할 수 있다. 특히 감성별 주제 차이 비교라는 본 과제의 목적에 적합하다.

- 주요 하이퍼파라미터:

파라미터	의미	본 분석 설정
α (alpha)	문서-토픽 분포 집중도	auto(자동 학습)
β (beta/eta)	토픽-단어 분포 집중도	auto(자동 학습)
K	토픽 수 (사용자 지정)	9(Coherence Score로 탐색)
passes	코퍼스 반복 학습 횟수	15

2. 데이터 탐색적 분석 (EDA)


2.1 데이터 셋 개요 및 결측값 처리

본 과제에서 사용할 데이터셋은 COVID-19 관련 트윗을 수집하여 수동으로 감성 레이블을 부여한 데이터이다. Train 데이터(Corona_NLP_train.csv) 총 41,157개 트윗을 분석 대상으로 하였다. OriginalTweet 및 Sentiment 컬럼 모두 결측값 0건으로 별도 처리가 불필요하였다.

컬럼명	타입	설명
Location	Text	트윗 작성자의 위치 정보
Tweet At	Date	트윗 작성 날짜
Original Tweet	Text	트윗 원문 (분석 대상 텍스트)
Label	Categorical	감성 레이블: Extremely Positive, Positive, Neutral, Negative, Extremely Negative



2.2 감성 레이블 분포

- 원본 5개 레이블 분포:



긍정 계열(Extremely Positive + Positive)이 전체의 43.8%로 가장 큰 비중을 차지하며, 부정 계열(Negative + Extremely Negative)은 37.4%, 중립은 18.7%로 나타났다.

- 3개 그룹 병합 후 분포:



데이터의 희소성 문제를 해결하고 감성 그룹 간 토픽의 변별력을 극대화하기 위해, 유사한 의미 체계를 가진 'Extremely' 레이블을 통합하여 3개의 핵심 감성 그룹(Positive, Neutral, Negative)으로 재분류하였다

감성별 트윗 길이를 분석한 결과, 긍정(214.8자)과 부정(209.8자) 트윗이 중립(168.2자) 트윗에 비해 평균적으로 약 40~45자 더 긴 것으로 나타났다. 이는 감정적 표현을 담은 트윗일수록 더 많은 내용을 서술하는 경향이 있음을 시사한다. 반면 중립 트윗은 사실 전달 위주의 짧은 문장이 많음을 알 수 있다.

3. 텍스트 전처리

3.1 전처리 파이프라인

본 분석에서는 텍스트 데이터의 노이즈를 제거하고 모델의 해석력을 높이기 위해 다음과 같은 전처리 파이프라인을 구축하였다.

단계	처리 내용	근거
1	URL 제거	특수문자 제거 전에 먼저 수행하여 URL 패턴 인식
2	소문자 변환	동일 단어의 대소문자 변형 통일
3	특수문자, 숫자 제거	영문자와 공백만 남겨 노이즈 제거. 트위터 특성상 이모지, 해시태그 기호 등 제거
4	토큰화	공백 기준으로 단어 단위 분리
5	불용어 제거	의미 없는 빈도 상위 단어 제거로 토픽 품질 향상
6	표제어 추출 (Lemmatization)	단어 원형 복원 및 차원 축소. 어간 추출(Stemming)보다 의미 보존력이 높아 선택
7	짧은 단어 제거	2글자 이하 단어 제거 (전치사, 대명사 등)

3.2 불용어 설정

```
# 추가 불용어 (코로나 데이터 특화)
custom_stop = {'coronavirus', 'covid', 'covid19', '19', 'amp', 'u', 'get',
               'would', 'could', 'also', 'one', 'two', 'people', 'like',
               'know', 'think', 'make', 'even', 'well', 'really', 'say', 'just'}
stop_words = stop_words.union(custom_stop)
```

NLTK의 기본 불용어 외에, 모든 트윗에 공통적으로 등장하여 변별력이 낮은 단어들을 커스텀 불용어로 지정하여 제거하였다. 'coronavirus, covid' 등은 모든 트윗에 공통으로 등장하여 감성별 토픽을 구분하는 데 기여하지 않으므로 제거하였다.

3.3 전처리 결과

항목	값
전처리 전 문서 수	41,157개
유효 문서 수 (토큰 5개 이상)	39,224개
제거된 문서 수	1,933개 (4.7%)
최종 사전 크기	5,827단어
최종 코퍼스 크기	39,224문서

4. LDA 토픽 모델링


4.1 최적 토픽 수 선정

LDA에서 토픽 수 K는 사전에 지정해야 하는 하이퍼파라미터로, 데이터 기반의 객관적 선정이 필요하다. 본 분석에서는 Coherence Score와 Perplexity 두 가지 지표를 활용하여 K=2~12 범위에서 최적값을 설정하였다.

- 지표 설명:

- Coherence Score: 토픽 내 상위 단어들이 의미적으로 얼마나 일관성 있는지 측정. 값이 높을수록 토픽 품질 우수 (0.4 이상: 양호, 0.55 이상: 우수)
- Perplexity: 모델이 데이터를 얼마나 잘 설명하는지 측정. 값이 낮을수록 좋음

- 탐색 결과:



K=9에서 Coherence Score가 0.4 이상의 양호한 수준을 충족하며 0.4647로 탐색 범위 전체에서 최댓값이자 Elbow Point이다. Perplexity 역시 K=9 이후 감소하는 추세로 K=9가 적정 복잡도임을 보여준다.

4.2 감성별 모델 구축 과정

각 감성 그룹에 대해 독립적인 사전과 코퍼스를 구성한 후 LDA를 학습하였다. 감성마다 자주 사용되는 어휘가 다르므로 공통 사전이 아닌 감성별 독립 사전을 사용하는 것이 각 그룹의 특성을 더 정확하게 반영한다.

- 모델 설정: num_topics=9, passes=15, alpha=auto, eta=auto, random_state=42
- 감성별 학습 결과 요약:

감성	문서 수	사전 크기	Coherence Score
Positive	17,571	3,507단어	0.4584
Neutral	6,658	1,466단어	0.3636
Negative	14,995	3,256단어	0.4102

Neutral의 Coherence Score가 상대적으로 낮은 것은 중립 트윗의 문서 수(6,658개)가 긍정·부정에 비해 적고, 중립적 내용 특성상 단어 다양성이 낮기 때문으로 해석된다.

5. 결과 분석 및 비교

5.1 감성별 토픽 비교

실제 분석 결과로 도출된 상위 단어를 바탕으로 먼저 토픽별 상위 단어 목록을 직접 검토하여 1차적으로 정성적 해석을 수행하였고, 이후 대규모 언어 모델(LLM)인 Claude를 활용하여 해석의 타당성을 검증하고 토픽 명칭을 최종 확정하였다. 즉, 주관적 해석과 LLM간의 교차 검증을 통해 토픽 해석의 일관성과 객관성을 높이고자 하였다.

- Positive (K=9):

토픽	상위 10 개 단어 (Top Words)	토픽 명칭	해석
Topic 0	price, market, oil, government, high, state, economy, gas, low, sale	경제·유가 낙관	유가 하락과 경제 변화를 긍정적 시각으로 바라보는 트윗
Topic 1	online, shopping, home, stay, safe, help, delivery, keep, time, order	안전한 온라인 쇼핑	집에 머물며 온라인으로 안전하게 쇼핑하는 생활 방식 응원
Topic 2	worker, thank, store, staff, health, employee, care, grocery, driver, working	필수 노동자 감사	마트·의료 등 필수 노동자에 대한 감사와 응원
Topic 3	supermarket, need, time, please, work, store, see, good, local, day	마트 이용 당부	슈퍼마켓 방문 시 협조 요청 및 긍정적 격려
Topic 4	new, consumer, social, distancing, read, change, behavior, data, post, china	소비 행동 변화	사회적 거리두기로 인한 소비자 행동 변화에 대한 긍정적 보도
Topic 5	consumer, pandemic, business, product, company, outbreak, support, help, free, industry	비즈니스 지원	팬데믹 속 기업과 소비자를 지원하려는 움직임
Topic 6	food, demand, stock, supply, help, bank, community, increased, chain, trump	식품 공급망 지원	푸드뱅크, 지역 사회 식품 지원 등 커뮤니티 연대
Topic 7	grocery, store, toiletpaper, paper, toilet, socialdistancing, thing, going, life, buy	마트 사재기 현상	화장지 등 생필품 사재기 현상을 담담하게 묘사
Topic 8	hand, sanitizer, mask, face, glove, soap, fight, alcohol, water, wearing	방역 물품 긍정	손 소독제·마스크 착용 등 방역 수칙 실천 독려


- Neutral (K=9)

토픽	상위 10 개 단어 (Top Words)	토픽 명칭	해석
Topic 0	store, grocery, socialdistancing, line, stayhome, see, today, shopper, going, travel	마트 현황 보도	마트 줄서기, 사회적 거리두기 현황을 객관적으로 전달
Topic 1	consumer, change, new, trend, retail, pandemic, read, habit, may, daily	소비 트렌드 분석	팬데믹으로 인한 소비 트렌드 변화 분석 보도
Topic 2	price, oil, market, consumer, pandemic, impact, amid, data, outbreak, due	시장 지표 보도	유가·시장 가격 변동에 관한 중립적 데이터 보도
Topic 3	supermarket, lockdown, day, time, need, new, local, week, coronacrisis, staff	봉쇄 조치 현황	록다운 시행과 슈퍼마켓 운영 현황 전달
Topic 4	sanitizer, hand, marketing, food, march, week, american, brand, pandemic, april	방역 물품 시장	손 소독제 마케팅·브랜드 동향 분석
Topic 5	toiletpaper, toilet, paper, supermarket, mask, corona, need, dont, quarantine, roll	생필품 부족 현상	화장지·마스크 품귀 현상에 대한 객관적 보도
Topic 6	consumer, behavior, supply, business, chain, food, via, pandemic, surge, impact	공급망 분석	팬데믹에 따른 공급망 및 소비자 행동 분석
Topic 7	price, stock, food, mask, state, protection, trump, market, country, china	정책·시장 보도	트럼프 행정부 정책과 시장 가격 보도
Topic 8	shopping, online, store, food, grocery, home, retail, essential, delivery, customer	온라인 쇼핑 현황	온라인 식품·필수품 쇼핑 증가 현황 보도

- Negative (K=9):

토픽	상위 단어 (Top Words)	토픽 명칭	해석
Topic 0	food, panic, buying, stop, shelf, buy, stock, toilet, paper, toiletpaper	패닉 바잉 비판	식료품·화장지 사재기 행위에 대한 분노와 비판
Topic 1	price, oil, pandemic, market, due, low, global, amid, cut, outbreak	경제 위기 우려	유가 폭락과 글로벌 시장 붕괴에 대한 불안
Topic 2	gas, line, trump, medical, money, walmart, realdonaldtrump, front, stayathome, ppe	정치·의료 불만	트럼프 행정부의 의료·경제 대응에 대한 비판
Topic 3	sanitizer, hand, russia, kill, man, virus, saudi, selling, drug, fight	방역 물품 폭리 비판	손 소독제 폭리·허위 약품 판매에 대한 분노
Topic 4	store, supermarket, grocery, time, worker, going, mask, work, need, dont	마트 노동자 위협	마스크 없이 일하는 마트 노동자의 위험한 환경 비판
Topic 5	consumer, scam, news, report, state, call, protection, check, related, gouging	사기·가짜 뉴스 피해	팬데믹 관련 사기와 허위 정보 피해 고발
Topic 6	food, demand, supply, chain, bank, job, opec, recession, stock, million	공급망 붕괴·실업	공급망 붕괴, 실직, 경기 침체에 대한 우려
Topic 7	consumer, crisis, business, demand, country, across, farmer, company, industry, spending	경제 전반 위기	기업 도산, 농업 위기 등 경제 전반의 붕괴 우려
Topic 8	shopping, online, home, delivery, stay, social, order, case, supermarket, vulnerable	온라인 쇼핑 불만	배송 지연, 재고 부족 등 온라인 쇼핑 불편 호소

5.2 감성별 핵심 주제 비교 분석



감성별 대표 토픽 분포 비교 시각화 결과를 바탕으로 감성 간 핵심 차이를 아래와 같이 분석하였다.

비교 테마	감성 레이블	상위 키워드 (Top Words)	관점 및 해석 차이
① 방역 물품	Positive	hand, sanitizer, mask, face, glove, soap, fight	방역 수칙 실천 독려 및 공동체적 극복 의지
	Neutral	shopping, online, store, food, grocery, essential	온라인을 통한 필수 방역용품 수급 현황 보도
	Negative	shopping, online, home, delivery, order, case	배송 지연, 재고 부족 등 온라인 쇼핑의 불편함 호소
② 식품·공급망	Positive	food, demand, stock, supply, help, community	푸드뱅크 운영 및 지역 사회 연대와 지원 강조
	Neutral	consumer, behavior, supply, business, chain, via	팬데믹에 따른 공급망 변화를 객관적으로 분석
	Negative	food, demand, supply, chain, job, recession	공급망 붕괴로 인한 실직 및 경기 침체 우려 표출
③ 가격·경제	Positive	price, market, oil, government, high, economy	경제 지표 변화를 정보 공유 및 긍정적 시각으로 접근
	Neutral	store, grocery, socialdistancing, line, today	마트 대기 줄 등 현장 상황 중심의 사실 전달
	Negative	food, panic, buying, stop, shelf, buy, toilet	사재기(Panic Buying) 및 품귀 현상에 대한 비판

6. 결론 및 논의

6.1 분석 요약

- 데이터: COVID-19 트윗 41,157개 → 전처리 후 39,224개
- 감성 그룹: 5개 → 3개 병합 (긍정 43.8% / 중립 18.7% / 부정 37.4%)
- 전처리: URL 제거 → 소문자 → 특수문자 제거 → 불용어 제거 → 표제어 추출
- 최적 토픽 수: $K=9$ (Coherence Score 0.4647, $K=2\sim12$ 탐색)
- 모델: 감성별 독립 LDA 3개 (passes=15, alpha/eta=auto).

6.2 핵심 인사이트

- 같은 소재, 다른 감정: 마트, 온라인 쇼핑, 방역 물품이라는 공통 소재가 긍정 트윗에서는 '응원·연대', 중립 트윗에서는 '현황 분석', 부정 트윗에서는 '비판·불만'으로 전혀 다르게 표현되었다.
- 부정 트윗의 사회 문제 지적: 부정 트윗에서만 정치 비판(trump), 폭리·사기(scam, gouging), 경기 침체(recession, opec) 관련 토픽이 뚜렷하게 나타났다. 이는 부정적 감성을 가진 사용자들이 단순 불만을 넘어 구조적 문제를 지적하는 경향이 있음을 시사한다.
- 중립 트윗의 분석적 성격: 중립 트윗은 trend, data, behavior, impact, analysis 등 분석적 어휘가 두드러져, 미디어 보도나 연구 관련 트윗이 중립으로 분류되는 경향이 있음을 확인하였다.
- 팬데믹 초기 주요 관심사: 전체적으로 식품 및 생필품 구매, 방역 물품, 온라인 쇼핑 전환, 경제 및 유가 변동이 COVID-19 초기의 소셜 미디어의 핵심 화제 키워드임을 확인하였다.

6.3 한계점

본 연구는 트위터 특유의 텍스트 노이즈 (붙여쓰기 등)와 LDA의 문맥 파악 한계 (Bag of Words 방식)로 인해 섬세한 의미 포착에 한계가 있다. 특히 분석 효율을 위해 감성 레이블을 병합하는 과정에서 감성 강도 정보가 소실되었으며, 중립 데이터의 희소성으로 인해 해당 그룹의 토픽 품질(Coherence 0.3636)이 상대적으로 낮게 나타났다. 향후 BERTopic과 같은 문맥 기반 모델 도입과 데이터 불균형 해소를 통해 분석의 정교함을 보완할 필요가 있다.

6.4 향후 개선 방향

본 연구의 한계를 보완하기 위해 향후 문맥 파악에 특화된 BERTopic 도입과 날짜 기반의 시계열 분석을 하여 토픽 수준을 질적으로 높여 더욱 입체적인 인사이트 도출이 가능할 것이다. 또한, 5개의 감성 레이블의 유지를 통해 감성 강도별 차이를 심층적으로 분석하고, 위치 정보를 결합하여 국가 및 지역별 문화적 배경에 따른 대중 커뮤니케이션의 특성도 포괄적으로 이해가 가능할 것으로 기대된다.