

코드 분석보고서

- Classification, Clustering -

분류(Classification) 알고리즘을 활용한 고객 이탈 예측 및
군집(Clustering) 분석을 통한 고객 세분화

1. 서론

1.1 분석 목적

본 분석의 목적은 통신사 고객 데이터를 활용하여 고객의 이탈(Churn) 여부를 예측하고, 동시에 고객을 의미 있는 집단으로 세분화하는 것이다. 분류(Classification) 분석을 통해 어떤 고객이 이탈할 가능성이 높은지를 예측하고 주요 영향 요인을 파악하며, 군집(Clustering) 분석을 통해 고객을 특성이 유사한 집단으로 나누어 세분화한다. 또한, 두 분석 결과를 종합하여 통신사의 고객 유지(Retention) 전략에 대한 시사점을 도출하고자 한다.

1.2 분류와 군집의 개요 - 지도학습 vs 비지도학습

분류는 정답(Label)이 주어진 데이터로 모델을 학습시켜 새로운 데이터의 범주를 예측하는 지도학습(Supervised Learning)이다. 본 과제에서는 이탈 여부(Churn=Yes/No)라는 정답이 존재하므로, 이를 예측하는 것이 분류 문제에 해당한다. 반면 군집은 정답 없이 데이터 내부의 유사성만으로 비슷한 개체끼리 묶는 비지도학습(Unsupervised Learning)이다. 이탈 여부를 사용하지 않고 고객의 이용 특성만으로 집단을 형성한 뒤, 사후적으로 각 집단의 이탈 경향을 해석한다. 즉 분류는 '예측'에, 군집은 '발견'에 초점이 있다.

2. 데이터 탐색적 분석 (EDA)

2.1 데이터 셋 기본 정보

데이터셋은 통신사 고객 7,043명에 대한 21개 변수로 구성된다. 고객 식별자(customerID), 성별·고령자 여부 등 인구통계 정보, 가입 서비스(전화·인터넷·부가서비스), 계약 형태(Contract)·결제 방식(PaymentMethod), 가입 기간(tenure)·월 요금(MonthlyCharges)·총 요금(TotalCharges), 그리고 타겟 변수인 이탈 여부(Churn)를 포함한다. 기술통계 확인 결과 가입 기간은 평균 약 32.4개월, 월 요금은 평균 약 64.8달러였으며, 명시적 결측치(NaN)는 존재하지 않았다.

2.2 타겟 변수(Churn) 분포




그림1. 고객 이탈 여부 분포 (좌: 빈도, 우: 비율)

이탈 고객은 전체의 26.5%(1,869명), 비이탈 고객은 73.5%(5,174명)로, 두 클래스 간 약 2.8:1의 불균형이 존재한다. 이러한 클래스 불균형은 정확도(Accuracy)만으로 모델을 평가할 경우 '모두 비이탈로 예측'해도 73.5%의 정확도가 나오는 착시를 유발하므로, 이후 평가에서 Recall·F1 등 보조

지표를 함께 고려해야 할 것이다.

2.3 주요 변수별 이탈률 비교




그림2. 주요 범주형 변수별 이탈률

범주형 변수별 이탈률을 비교한 결과, 월 단위 계약(Month-to-month)·광케이블 인터넷(Fiber optic)·전자수표(Electronic check) 결제 고객의 이탈률이 두드러지게 높게 나타났다. 특히 계약 형태(Contract)는 이탈률 차이가 가장 큰 변수로(Month-to-month 42.7% vs Two year 2.8%), 장기 약정이 없는 고객일수록 이탈 위험이 크다는 점을 확인할 수 있다.




그림3. 주요 연속형 변수의 이탈 그룹별 분포

연속형 변수를 이탈/비이탈 그룹으로 비교한 결과, 이탈 고객은 가입 기간(tenure)이 짧은 초기 구간(0~10개월)에 집중되고 월 요금(MonthlyCharges)이 높은 구간(70~110달러)에 몰려 있다. 총 요금(TotalCharges)도 낮은 구간에 분포하는데, 이는 가입 기간이 짧은 이탈 고객의 특성이 반영된 결과다. 종합하면 '가입 기간이 짧고 월 요금이 높은 신규·고요금 고객'이 이탈에 가장 취약하며, 이는 군집 분석에서 이탈률이 가장 높았던 C2(신규 고요금 위험 고객) 집단과 일치한다.

2.4 상관관계 분석




그림4. 수치형 변수 간 상관관계 히트맵

수치형 변수 간 상관관계를 확인한 결과, 총 요금(TotalCharges)은 가입 기간 및 월 요금과 강한 양의 상관을 보였다. 이는 총 요금이 본질적으로 ‘가입 기간 × 월 요금’의 누적값이기 때문이며, 군집 분석 시 세 변수를 함께 사용할 때 정보가 일부 중복될 수 있음을 의미한다.

3. 전처리

3.1 결측치 및 이상치 처리

TotalCharges는 데이터 타입이 문자열(object)로 저장되어 있어 일반적인 결측치 탐지(isnull)로는 잡히지 않았다. 문자열 공백(' ')을 직접 검사한 결과 11건의 숨은 결측치 확인되었으며, 이 11건은 모두 가입 기간(tenure)이 0인 신규 고객이었다. 가입 직후로 누적 요금이 발생하지 않은 상태이므로 총 요금을 0으로 대체하는 것이 데이터의 실제 의미에 부합한다고 판단하여 0으로 처리하였다.




그림5. 연속형 변수 박스플롯 (IQR 기준 이상치 0건)

이상치는 연속형 변수(tenure, MonthlyCharges, TotalCharges)에 대해 박스플롯과 IQR($Q1 - 1.5 \times IQR \sim Q3 + 1.5 \times IQR$) 기준으로 점검하였다. 세 변수 모두 IQR 기준 이상치가 0건으로 확인되어, 별도의 이상치 제거 없이 분석을 진행했다.

3.2 인코딩 · 스케일링 · 데이터 분리

- 인코딩: 식별자(customerID)를 제거하고, 타겟 Churn은 Yes=1/No=0으로 라벨 인코딩하였다. 나머지 범주형 변수는 원-핫 인코딩(get_dummies, drop_first=True)으로 변환하여 명목형 변수에 인위적 순서가 부여되지 않도록 하였다. 그 결과 설명변수는 총 30개가 되었다.
- 스케일링: 연속형 변수 3개(tenure, MonthlyCharges, TotalCharges)에 StandardScaler를 적용했다. 데이터 누수를 막기 위해 학습 데이터에만 fit하고 테스트 데이터에는 transform만 적용했다.
- 데이터 분리: 학습 80%/테스트 20%로 분리하였으며, 학습·테스트 모두 이탈률 26.5%가 동일하게 유지되어 정상 적용되었음을 확인하였다(학습 5,634건 / 테스트 1,409건).

4. 분류 모델링

4.1 모델 구축

과제에서 요구한 핵심 3개 알고리즘인 의사결정나무(Decision Tree, criterion=entropy, 즉 Information Gain 기준), 나이브 베이즈(Gaussian Naïve Bayes), KNN에 더해, 추가로 로지스틱 회귀·SVM·랜덤 포레스트·그래디언트 부스팅을 함께 구축하여 총 7개 모델의 성능을 비교하였다. KNN은 유클리디안 거리를 사용하였으며, K=1~30 범위에서 F1-score가 가장 높은 K를 탐색한 결과 K=29가 선택되었다.




그림6. KNN의 K값에 따른 성능 변화 (Euclidean)

불균형 데이터 특성상 K가 커질수록 이웃의 다수가 비이탈 클래스로 채워져 다수 클래스 쪽으로 예측이 수렴하는 경향이 나타났으며, 그 결과 비교적 큰 K(=29)가 선택되었다.

4.2 성능 비교

7개 모델의 테스트 성능을 종합하면 다음과 같다(F1-Score 내림차순)

모델	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Logistic Regression	0.806	0.659	0.559	0.605	0.842
KNN (K=29)	0.794	0.618	0.588	0.603	0.834
Naive Bayes	0.656	0.427	0.866	0.572	0.809
Gradient Boosting	0.798	0.654	0.505	0.570	0.842
Random Forest	0.790	0.629	0.508	0.562	0.826
SVM	0.795	0.655	0.481	0.555	0.795
Decision Tree	0.792	0.648	0.473	0.547	0.827

표1. 7개 모델 테스트 성능 비교 표

F1-Score 기준 최고 성능은 로지스틱 회귀(0.605)였고, KNN(0.603)이 근소한 차이로 뒤를 이었다. ROC-AUC 기준으로는 로지스틱 회귀와 Gradient Boosting이 0.842로 가장 우수하여, 판별력이 전반적으로 높음을 확인하였다. 반면 나이브 베이즈는 정확도(0.656)는 낮지만 Recall이 0.866으로 압도적으로 높아, 이탈 고객을 놓치지 않는 데 특화된 모델임을 알 수 있다.

4.3 Type I / Type II 오류의 비즈니스적 의미

혼동행렬에서 Type I Error(FP)는 유지할 고객을 이탈로 잘못 예측하는 경우로, 불필요한 리텐션 마케팅 비용을 유발한다. Type II Error(FN)는 이탈할 고객을 유지로 잘못 예측하여 놓치는 경우로, 고객 자체를 상실하게 된다. 신규 고객 획득 비용이 기존 고객 유지 비용의 수 배에 달한다는 점을 고려하면, 일반적으로 FN(이탈 고객을 놓침)의 비용이 더 크다. 따라서 본 분석에서는 단순 정확도보다 이탈 고객을 얼마나 포착하는가를 나타내는 Recall과, 정밀도-재현율의 균형인 F1-Score를 핵심 지표로 삼는다.




그림 7. 분류기별 혼동행렬

모 델	FP (Type I)	FN (Type II)	Recall(이탈탐지율)
Naive Bayes	435	50	0.866
KNN (K=29)	136	154	0.588
Logistic Regression	108	165	0.559
Random Forest	112	184	0.508
Gradient Boosting	100	185	0.505
SVM	95	194	0.481
Decision Tree	96	197	0.473

표2. 7개 모델 오류 비교

나이브 베이즈는 FN을 단 50건으로 최소화(Recall 0.866)하지만 FP가 435건으로 많아, ‘위험 고객을 폭넓게 잡되 오탐도 감수하는’ 전략에 적합하다. 반대로 의사결정나무·SVM은 FP는 적지만 FN이 190건 이상으로 많아 이탈 고객을 다수 놓친다. 비용 구조상 FN을 줄이는 것이 중요하다면 나이브 베이즈 또는 후술할 SMOTE 적용 모델이 유리할 것이다.

4.4 주요 변수 분석 (Feature Importance)

의사결정나무의 변수 중요도를 분석한 결과, 계약 형태(Contract)·가입 기간(tenure)·인터넷 서비스 유형(Internet Service) 관련 변수가 이탈 예측에 가장 큰 영향을 미치는 것으로 나타났다. 이는 EDA에서 확인한 ‘월 단위 계약·단기 가입·광케이블 고객의 높은 이탈률’과 일치한다.




그림 8. 의사결정나무 변수 중요도 (상위 15개)




그림 9. ROC 곡선 - 분류기 비교

4.5 SMOTE를 활용한 클래스 불균형 처리

이탈 클래스(26.5%)가 소수임을 고려하여, 학습 데이터에만 SMOTE 오버샘플링을 적용하며 테스트는 원본 분포 유지하여 대표 모델의 성능 변화를 비교한다.

모델	Accuracy	Precision	Recall	F1-Score
Logistic Regression	0.806	0.659	0.559	0.605
Logistic Regression + SMOTE	0.762	0.537	0.743	0.623
Random Forest	0.790	0.629	0.508	0.562
Random Forest + SMOTE	0.772	0.561	0.644	0.600

표3. SMOTE 적용 전후 성능 비교

SMOTE 적용 후 두 모델 모두 Recall이 크게 상승(로지스틱 0.559→0.743, 랜덤포레스트 0.508→0.644)하였고 F1-Score도 함께 개선되었다. Precision은 다소 하락했으나, 이탈 고객을 놓치는 비용(FN)이 더 큰 비즈니스 맥락에서는 합리적인 트레이드오프로 평가할 수 있다.

5. 군집 분석 - 고객 세분화

5.1 변수 선택 및 적정 군집 수 결정

군집 분석에는 고객의 이용 규모와 충성도를 대표하는 연속형 변수 3개(tenure, MonthlyCharges, TotalCharges)를 선택하고 StandardScaler로 표준화하였다. K=2~8에 대해 SSE와 실루엣 계수를 계산한 결과, SSE는 K=4 부근에서 감소세가 완만해지는 엘보우를 보였고 실루엣 계수도 K=4에서 0.472로 양호하여 최종 군집 수를 4로 결정하였다. 또한 K=2는 세분화가 너무 거칠어 제외하고, 엘보우와 실루엣을 함께 고려해 K=4 선택한다.




그림10. 엘보우 차트 및 실루엣 계수

5.2 군집별 특성 분석 및 네이밍

K=4로 군집화한 결과 각 군집의 평균 특성과 이탈률은 다음과 같다. 군집별 이탈률은 군집 결과를 실제 이탈 여부와 교차하여 산출하였다.

군집 (라벨)	가입기간(월)	월요금(\$)	총요금(\$)	고객수(비중)	이탈률(%)
C0 신규 저요금	10.2	31.8	302	1,703 (24.2%)	24.7
C1 장기 고액 충성	59.5	93.3	5,549	1,904 (27.0%)	15.4
C2 신규 고요금 위험	15.4	80.8	1,251	2,276 (32.3%)	48.2
C3 장기 저요금 안정	53.6	34.9	1,836	1,160 (16.5%)	5.0

표4. 군집별 특성 및 이탈률 요약

각 군집에 비즈니스적 의미를 부여하면 다음과 같다.

- C0 (신규 저요금 고객) / 가입 초기·저요금 고객: 이탈률 24.7%로 평균 수준이며 향후 성장 가능성이 있는 집단
- C1 (장기 고객 충성 고객) / 가입 기간이 길고 요금·누적금액이 가장 큰 고수익 집단: 이탈률 15.4%로 안정적
- C2 (신규 고요금 이탈위험 고객) / 가입 기간은 짧지만 월 요금이 높은 집단: 이탈률 48.2%로 4개 군집 중 가장 높아 핵심 관리 대상
- C3 (장기 저요금 안정 고객) / 오래 유지된 저요금 고객: 이탈률 5.0%로 가장 충성도가 높은 집단




그림 11. 군집 산점도 (가입기간 vs 월요금)




그림 12. PCA 2차원 군집 시각화

5.3 분류-군집 교차 분석

군집과 실제 이탈 여부를 교차한 결과, 가입 기간이 짧은 신규 고객 군집(특히 C2 신규 고요금 위험)에서 이탈률이 가장 높았다. 동일한 ‘신규’ 고객이라도 월 요금이 높은 C2(48.2%)는 월 요금이 낮은 C0(24.7%)보다 이탈률이 약 2배 높아, 높은 요금에 대한 부담이 초기 이탈의 핵심 동인임을 시사한다. 반대로 장기 고객(C1, C3)은 이탈률이 5~15%로 낮아, 가입 기간이 길어질수록 이탈 위험이 급격히 감소함을 확인할 수 있다.

5.4 DBSCAN · 계층적 군집

K-Means 외 알고리즘으로 DBSCAN과 계층적 군집(Ward)을 추가로 시도하였다. DBSCAN($\text{eps}=0.5$, $\text{min_samples}=10$)은 현재 파라미터에서 노이즈 없이 단일 군집으로 묶여, 본 데이터의 밀도 구조상 eps 등 파라미터 재조정이 필요함을 보여주었다. 계층적 군집은 K-Means와 조정 랜드 지수(ARI) 0.55로 중간 정도의 일치를 보여, 두 방법이 대체로 유사하나 경계 영역에서는 차이가 있음을 확인하였다.




그림 13. DBSCAN 및 계층적 군집 결과 (PCA 2D)

6. 결론 및 논의

6.1 분석 요약

본 분석에서는 7개 모델 중 로지스틱 회귀가 $F1=0.605$ / $AUC=0.842$ 로 가장 균형 잡힌 성능을 보였으며, 나이브 베이즈는 $\text{Recall}=0.866$ 으로 이탈 고객 포착에 특화되어 있었다. 군집 분석에서는 $K=4$ 로 고객을 세분화하였고, ‘신규 고요금 위험 고객(C2)’ 집단의 이탈률이 48.2%로 가장 높게 나타났다.

6.2 이탈 고객 프로필

분류 모델의 변수 중요도와 EDA·군집 결과를 종합하면, 이탈 가능성이 높은 고객은 다음 특성을 갖는다: ① 월 단위(Month-to-month) 계약, ② 짧은 가입 기간, ③ 높은 월 요금(특히 광케이블 인터넷), ④ 전자수표 결제. 즉 ‘장기 약정 없이 가입한 지 얼마 안 된 고요금 고객’이 핵심 이탈 위험군이다.

6.3 군집별 차별화 전략

- C2 (신규 고요금 위험, 48.2%): 가입 초기 온보딩 강화와 첫 3~6개월 요금 안정화·서비스 번들 할인으로 조기 이탈을 방어한다. 광케이블 품질·요금 불만을 선제적으로 관리하고, 연 단위 계약 전환 인센티브를 제공한다.
- C1 (장기 고액 충성, 15.4%): 멤버십·우선 기술지원 등 로열티 프로그램으로 유지하고, 부가서비스 업셀링으로 생애가치를 극대화한다. 이 집단의 유지가 곧 고수익으로 직결된다.
- C0 (신규 저요금): 부가서비스 교차판매로 이용 관여도를 높이고, 장기 계약 전환을 유도하여 C3 같은 안정 고객으로 전환시킨다.

6.4 종합 고객 유지(Retention) 전략 제언

분류 모델로 개별 고객의 이탈 확률을 스코어링하고, 군집 분석으로 고객을 세그먼트화한 뒤, 세그먼트별로 차별화된 리텐션 액션(가격·계약·서비스)을 매칭하는 2단계 타겟 마케팅을 제안한다. 비용 관점에서 이탈 고객을 놓치는 FN의 손실이 더 크므로, 위험군을 폭넓게 포착할 때는 Recall이 높은 모델(나이브 베이즈 또는 SMOTE 적용 모델)을 활용하고, 정밀 타겟팅에는 로지스틱 회귀, 그래디언트 부스팅의 확률 점수를 활용하는 운영이 효과적일 것이다.

6.5 한계점 및 향후 방향

- 클래스 불균형: SMOTE 외에 비용 민감 학습(class_weight), 임계값(threshold) 조정으로 Recall-Precision 균형을 더 정교하게 최적화할 수 있다.
- 모델 고도화: XGBoost·LightGBM, GridSearchCV 기반 하이퍼파라미터 최적화, 교차검증 기반 평가로 일반화 성능을 강화할 수 있다.
- KNN의 한계: 불균형 데이터에서 큰 K가 선택되며 다수 클래스로 쏠리는 경향이 있으므로, 거리 가중(weights) 방식이나 임계값 조정을 함께 고려할 필요가 있다.
- 군집 안정성: K-Means는 초기값·구형 가정에 민감하므로 DBSCAN 파라미터 튜닝, GMM 등과의 교차 검증이 필요하다.
- 데이터 한계: 고객 민원·통화·이용 로그 등 행동·시계열 데이터를 추가하면 예측력과 세분화의 해상도를 더 높일 수 있다.