

코드 분석보고서

- Link Prediction -

네트워크 링크 예측:

소셜/인용 네트워크를 활용한 Link Prediction 모델링

1. 서론

1.1 분석 배경 및 목적

본 보고서는 Facebook Social Circles 네트워크 데이터셋을 활용하여 링크 예측(Link Prediction) 모델을 구현하고 비교 분석한다. 링크 예측은 그래프에서 현재 존재하지 않는 두 노드 사이의 연결이 미래에 형성될 가능성을 예측하는 문제로, 이진 분류(Binary Classification) 문제로 정형화된다.

1.2 링크 예측의 응용 배경

링크 예측은 다양한 분야에서 핵심 기술로 활용된다:

- 소셜 네트워크 - "알 수도 있는 사람" 추천 (Facebook, LinkedIn)
- 추천 시스템 - 사용자-아이템 관계에서 구매/클릭 예측 (Netflix, Amazon)
- 지식 그래프 - 엔티티 간 새로운 관계 탐색 (Wikidata, Freebase)
- 생물정보학 - 단백질-단백질 상호작용 예측, 약물 부작용 예측
- 학술 네트워크 - 논문 인용 예측

2. 데이터 탐색적 분석 (EDA)

2.1 데이터 셋 개요 및 선정 근거

본 과제에서 사용할 데이터셋은 Facebook 데이터셋으로 실제 소셜 네트워크의 클러스터링 특성(높은 밀도, 커뮤니티 구조, 허브 노드 존재)을 잘 반영하여, 각 방법론의 장단점을 명확하게 비교할 수 있다. 또한 OGB 데이터셋보다 규모가 적절하여 GCN 학습 시간이 합리적이다. 개인적으로 개발 중인 블로그 분석 서비스에 사용자 간 친구 추천 기능 추가를 계획하고 있어, 실제 소셜 네트워크 구조의 Facebook 데이터셋을 통해 링크 예측 방법론의 적용 가능성을 탐색하고자 선택하였다.

데이터 셋	노드 수	엣지 수
Facebook	4,039	88,234

2.2 문제 정의

주어진 그래프 $G = (V, E)$ 에서 훈련 엣지를 학습한 뒤, 테스트 엣지 집합 내 각 노드 쌍 (u, v) 에 대해 연결 여부를 예측한다

- 레이블 1 (Positive): 실제로 존재하는 엣지
- 레이블 0 (Negative): 존재하지 않는 무작위 노드 쌍


2.3 기본 네트워크 통계량

링크 예측 모델 선택에 앞서, 네트워크의 구조적 특성을 파악하는 탐색적 분석을 수행하였다. 아래 표는 실제 분석에서 산출된 값이다.

지표	Facebook (실제)
노드 수 (사용자)	4,039
엣지 수(친구 관계)	88,234
네트워크 밀도	0.010820
평균 차수	43.69
최대 차수	1,045
평균 클러스터링 계수	0.6055
연결 성분 수	1
최대 연결 성분 크기	4,039


2.4 차수 분포 분석

Facebook 네트워크의 차수 분포를 분석한 결과, log-log 스케일에서 직선에 가까운 형태를 나타내어 Power-Law 분포에 가까운 특성을 보인다.




[그림 1] 선형 차수 분포 히스토그램

소수의 허브(hub) 노드가 매우 많은 연결을 가지며, 대다수 노드는 상대적으로 적은 연결을 가진다. 평균 차수가 43.69로 Cora(3.90)에 비해 매우 높은 연결 밀도로 공통 이웃 기반 휴리스틱이 효과적으로 동작할 것으로 예상할 수 있다. 또한 오른쪽 꼬리의 허브 노드들이 공통 이웃으로 등장할 때 Adamic-Adar가 가중치를 낮춰 노이즈를 줄여줄 것으로 기대한다.



[그림 2] log-log 차수 분포

log-log 스케일에서 전반적으로 우하향하는 형태를 보여 Power-Law 분포에 근사하며, 소수의 허브 노드가 존재함을 확인하였다. 다만 저차수 구간의 수평 구간은 Facebook ego-network의 최소 연결 특성을 반영한다.



[그림 3] 상위 20개 허브 노드 차수


상위 20개 허브 노드는 평균 차수(43.69)의 5~24배에 달하는 연결 수를 보유하며, 특히 Node 107은 최대차수가 1045로 네트워크 내 극단적 허브의 존재를 확인하였다.

2.5 클러스터링 계수 및 커뮤니티 구조

중심성 지표	평균	값
Degree Centrality	0.0108	최대: 0.2588
Betweenness Centrality	0.0007	최대: 0.4897
Clustering Coefficient	0.6055	최소: 0.0000


세 가지 중심성 지표를 산출하여 방법론 선택 및 결과 해석의 근거로 활용하였다.

- Degree Centrality: 대부분 노드는 전체의 1% 내외와 연결되나, 허브 노드(Node 107)는 전체의 약 26%와 연결되어 있다. 연결이 소수 허브에 집중된 구조로, Adamic-Adar가 CN보다 적합함을 알 수 있다.




[그림 4] Degree Centrality 분포

- Betweenness Centrality: 평균은 매우 낮으나 최대값이 약 0.49로, 소수 허브가 전체 경로의 절반에 관여하는 경로 집중 현상이 확인된다. 이는 Node2Vec 랜덤 워크가 허브를 과도하게 방문할 수 있다는 한계의 근거가 될 수 있다.




[그림 5] Betweenness Centrality

- Clustering Coefficient: 친구들끼리 서로 친구인 비율이 평균 60%로 커뮤니티 구조가 매우 강하다. 이는 공통 이웃 정보가 강력한 예측 신호로 작용하여 휴리스틱이 높은 성능을 보인 주요 근거이다.



[그림 6] Clustering Coefficient 분포



[그림 7] 허브 노드 중심 서브그래프 시각화

‘Node 107’을 중심으로 한 서브그래프에서 두 가지 구조가 관찰된다. 왼쪽의 밀집 그룹은 이웃 노드들끼리 서로 연결된 커뮤니티 구조를 나타내며, 오른쪽의 분산된 노드들은 허브를 통해서만 연결된 브릿지 구조를 보인다. 이는 평균 클러스터링 계수(0.6055)와 Betweenness Centrality 최대값(0.4897)을 동시에 설명하는 시각적 근거가 된다.

3. 데이터 전처리

3.1 학습/검증/테스트 엣지 분할

분할	비율	전체 엣지 수	Positive	Negative
Train	80%	141,176	70,588	70,588
Validation	10%	17,646	8,823	8,823
Test	10%	17,646	8,823	8,823

Cora 예시(85/5/10)와 달리 Facebook은 엣지 수가 88,234개로 충분하므로 검증셋 10%를 확보하여 GCN 하이퍼파라미터 조정에 활용하였다. 데이터 누수(leakage) 방지를 위해 테스트 엣지는 훈련 그래프에서 완전히 제거하였다.

3.2 Negative Sampling 전략

링크 예측은 연결 여부를 예측하는 이진 분류 문제이므로, 실제 존재하는 엣지(Positive)와 존재하지 않는 노드 쌍(Negative)을 모두 학습 데이터로 구성해야 한다. Negative 샘플이 과도하게 많을 경우 모델이 모든 쌍을 "연결 없음"으로 예측해도 높은 정확도가 나오는 클래스 불균형 문제가 발생한다. 이를 방지하기 위해 Positive:Negative = 1:1 비율로 무작위 uniform sampling을 적용하여 실제로 연결되지 않은 노드 쌍을 동수로 생성하였다.

3.3 노드 특성 처리

Facebook 데이터셋은 노드 특성이 제공되지 않으므로, 각 노드의 차수(degree)를 단일 특성(shape: 4039×1)으로 사용하였다. 차수는 노드의 네트워크 내 영향력을 나타내는 가장 기본적인 구조 정보이다. 단, 이 선택이 GCN 성능에 제약이 되었음을 5절에서 후술한다.

4. Link Prediction 모델링

3가지 계열의 방법론을 구현하여 비교하였다. 각 방법론의 핵심 수식과 하이퍼파라미터 선택 근거를 제시한다.

방법론	유형	핵심 원리
Common Neighbors	휴리스틱	공통 이웃 노드의 수
Jaccard Coefficient	휴리스틱	공통 이웃을 전체 이웃 합집합으로 정규화
Adamic-Adar	휴리스틱	저차수 공통 이웃에 높은 가중치 부여
Node2Vec	임베딩	편향 랜덤 워크 + Word2Vec 으로 64 차원 임베딩 학습
GCN	GNN	이웃 정보 집계 + 노드 특성 결합으로 임베딩 학습

4.1 휴리스틱 기반 (Heuristic)

NetworkX 패키지에 구현된 세 가지 휴리스틱 지표를 사용하여 학습 없이 네트워크 구조만으로 연결 가능성을 점수화하였다.

휴리스틱 방법	AUC	AP
Common Neighbors	0.9913	0.9893
Jaccard Coefficient	0.9891	0.9882
Adamic-Adar	0.9925	0.9917

Area Under ROC Curve는 ‘임계값에 상관없이 모델이 얼마나 잘 구분하는가’를 보기 위함이며, Average Precision을 통해 연결될 것으로 예측한 것 중 실제로 연결된 비율이 얼마나 높은지를 확인하고자 한다.

세 가지 휴리스틱 방법론 모두 AUC·AP 0.98 이상의 높은 성능을 달성하였다. 이는 클러스터링 계수가 높아 공통 이웃 정보만으로도 링크 예측이 충분히 가능한 네트워크 구조임을 반영한다. 그 중 Adamic-Adar(AUC 0.9925)가 가장 높은 성능을 보였는데, 허브 노드를 통한 공통 이웃에 낮은 가중치를 부여하여 노이즈를 줄인 결과로 해석된다.

- **Common Neighbors (CN):** 두 노드 u, v 의 공통 이웃 수를 연결 가능성 점수로 사용한다.
 - 수식: $\text{score}(u, v) = |N(u) \cap N(v)|$
 - 장점: 계산이 가장 단순하고 직관적
 - 단점: 차수가 높은 노드에 유리한 편향 (허브 노드가 공통 이웃으로 자주 등장)
- **Jaccard Coefficient:** CN을 정규화하여 degree가 큰 노드의 영향을 보정한다.
 - 수식: $\text{score}(u, v) = |N(u) \cap N(v)| / |N(u) \cup N(v)|$
 - 장점: 두 노드의 총 이웃 수에 독립적인 공정한 지표
 - 단점: 소수의 공통 이웃만 있는 경우 과소 평가될 수 있음

- **Adamic-Adar Index (AA)**: 희귀한 공통 이웃에 더 높은 가중치를 부여한다.
- 수식: $\text{score}(u,v) = \sum_{w \in N(u) \cap N(v)} 1/\log|N(w)|$
- 예시: 전문 분야 커뮤니티를 통해 연결된 두 사람은 관심사가 유사할 가능성 높음

4.2 Node2Vec 임베딩 기반

편향된 랜덤 워크로 노드 임베딩을 학습한 뒤 Logistic Regression으로 링크를 분류하였다.

- dimensions=64, walk_length=30, num_walks=200, workers=4: 공식 라이브러리 (eliorc/node2vec) 권장 기본값 활용
- p=1 (return parameter): 직전 노드로 돌아갈 확률 조정
- q=2 (in-out parameter): q>1이면 BFS (Breadth-First Search, 너비 우선 탐색) 성향
 - 커뮤니티 내 구조 포착에 유리, Facebook의 강한 커뮤니티 구조를 감안하여 q=2 선택
- 엣지 임베딩: Hadamard Product(원소별 곱) → Node2Vec 원논문(Grover & Leskovec, 2016)에서 링크 예측 태스크에 가장 안정적 성능 보고
- 분류기: Logistic Regression + StandardScaler(Train 기준 정규화, leakage 방지)

4.3 GCN (Graph Convolutional Network)

휴리스틱의 1-hop 이웃 정보의 한계를 보완하기 위해, 2-layer GCN으로 2-hop 이웃 정보를 집계하여 노드 임베딩을 학습하고, 두 노드 임베딩의 내적(dot product)으로 링크 점수를 계산하였다. 그러나 입력 특성이 차수(1차원)로 제한되어 표현력에 한계가 있었으며 이것이 휴리스틱 대비 낮은 성능의 주요 원인으로 판단된다.

4.4 하이퍼파라미터 설정 요약

방법론	하이퍼파라미터	설정값	선택 근거
데이터 분할	Train/Val/Test	80/10/10%	엣지 88,234 개로 충분 → Cora 보다 Test 비율 확대 가능
Neg. Sampling	비율 (pos:neg)	1:1	클래스 균형 유지로 분류기 편향 방지
Node2Vec	dimensions / p / q	64 / 1 / 2	q>1(BFS 성향): 커뮤니티 구조 강한 Facebook 에 적합
	walk_length / num_walks	30 / 200	평균 경로 길이 고려, 충분한 샘플 수 확보
GCN	hidden / out / lr	64 / 32 / 0.01	2-layer: 2-hop 이웃 정보 집계, Adam lr=0.01 안정적 수렴
	Dropout / Epochs	p=0.5 / 100	과적합 방지, Val AUC 기준 최적 모델 저장

5. 결과 분석 및 비교

5.1 평가 지표

세 가지 지표를 사용하여 다각적으로 모델 성능을 평가하였다:

- AUC (ROC 곡선 아래 면적): 임계값에 무관한 전반적 분류 성능. 1에 가까울수록 우수
- Average Precision (AP): Precision-Recall 곡선 아래 면적. 클래스 불균형에 민감하며 높은 정밀도 예측 능력 측정
- Hits@K (K=20, 50): 예측 점수 상위 K개 중 실제 positive 비율. 친구 추천 시스템의 실용적 성능 지표

5.2 성능 비교 결과

5가지 방법론의 성능을 AUC, AP, Hits@K 지표로 비교한 결과는 아래와 같다.


방법론	AUC	AP	Hits@20	Hits@50	유형
Common Neighbors	0.9913	0.9893	1.0000	1.0000	휴리스틱
Jaccard	0.9891	0.9882	1.0000	1.0000	휴리스틱
Adamic-Adar	0.9925	0.9917	1.0000	1.0000	휴리스틱
Node2Vec	0.9850	0.9797	0.9500	0.9800	임베딩
GCN	0.8325	0.8513	1.0000	1.0000	GNN

세 가지 휴리스틱이 GCN보다 훨씬 높은 성능(AUC 0.99 vs 0.83)을 달성하였다. 이는 단순히 방법론의 우열이 아닌, Facebook 네트워크의 구조적 특성에서 비롯된 결과이다.

- 휴리스틱이 높은 이유: 네트워크 구조와의 연계
 - 평균 클러스터링 계수 0.6055: 친구들끼리 서로 친구인 비율이 60%에 달해 공통 이웃 정보가 매우 강력한 예측 신호가 됨
 - 평균 차수 43.69: 노드마다 공통 이웃이 풍부하여 CN 점수의 변별력이 매우 높음
 - Adamic-Adar(AUC=0.9925)가 CN(AUC=0.9913)보다 성능이 높은 이유: Facebook의 소그룹(친구, 직장 동료 등)을 통한 연결은 허브보다 저차수 공통 이웃으로 연결되며, AA는 이에 더 높은 가중치를 부여함
 - Hits@20, Hits@50 = 1.0000: 상위 20~50개 예측이 모두 정확하므로 친구 추천 시스템으로 활용 가능함
- GCN이 낮은 이유: 노드 특성 부재의 한계
 - 노드 특성이 차수(1차원)뿐이라 GCN이 학습할 수 있는 정보가 극히 제한적
 - 구조 정보(그래프 구조)는 GCN 레이어를 통해 학습되지만, 풍부한 노드 특성(텍스트, 프로필 등)이 없어 표현력이 부족
 - 반면 휴리스틱은 공통 이웃이라는 매우 강력한 구조 정보를 직접 활용하므로 이 데이터셋에서 유리

- Node2Vec (AUC=0.9850)
 - 휴리스틱보다 소폭 낮음: 랜덤 워크 기반 전역 구조 학습이 오히려 국소 공통 이웃 정보를 희석시킴
 - Hits@20(0.95), Hits@50(0.98): 상위 예측에서 소수 오류 발생 → 전역 임베딩의 노이즈 영향

5.3 ROC 곡선 분석 및 시각화



[그림 8] 전체 방법론 ROC 곡선 비교 및 성능 지표 막대 그래프

ROC 곡선에서 휴리스틱 3종과 Node2Vec은 좌상단에 밀집하여 유사한 고성능을 보인 반면, GCN은 다른 방법론과 뚜렷한 차이를 보였다. 다만 Hits@20/50 기준으로는 GCN도 1.0을 달성하여, 상위 예측 정확도 면에서는 모든 방법론이 실용적 수준임을 확인할 수 있다.

5.4 오분류(Error) 분석 -GCN 기준

오분류 유형	값	주요 특징
False Positive	8,764 건	FP 노드 평균 차수합: 68.40
False Negative	7 건	TP 노드 평균 차수합: 170.46
전체 오분류율	0.4971	threshold=0.5 기준

GCN의 낮은 성능 원인을 오분류 패턴으로 분석하기 위해 GCN 오분류 사례를 분석했다. 오분류의 대부분이 False Positive(없는 링크를 있다고 예측)이며 False Negative(있는 링크를 없다고 예측)는 단 7건에 불과하다. 이는 GCN이 임계값 0.5 기준으로 대부분의 쌍을 ‘연결됨’으로 예측하는 경향을 보임을 의미한다.

- TP 엣지 평균 차수합 > FP 엣지 평균 차수합: 실제 연결된 쌍은 고차수 노드가 많고, FP는 저차수 노드 쌍에서 발생

- 원인: 1차원 차수 특성만으로는 연결/비연결 구분이 어려워, 모델이 모든 쌍에 비슷한 점수를 부여
- 개선 방안: 노드의 추가 특성(커뮤니티 소속, 공통 그룹 수 등) 또는 SEAL 같은 서브그래프 기반 방법 도입

6. 결론 및 논의

6.1 분석 요약

- 실제 성능 순위: Adamic-Adar $\approx$ CN $\approx$ Jaccard > Node2Vec >> GCN
- 휴리스틱의 우위는 Facebook 네트워크의 높은 클러스터링 계수(0.6055)와 평균 차수(43.69)에서 비롯됨
- GCN의 낮은 성능은 모델 자체의 한계가 아닌, 1차원 차수 특성이라는 입력 제약 때문
- Hits@20/50 기준으로는 모든 방법론이 1.0 또는 근접 $\rightarrow$ 상위 추천 정확도 면에서 모두 실용적

6.2 방법론별 장단점 요약

방법론	장점	단점
휴리스틱	해석 용이, 계산 빠름, 추가 학습 불필요	국소 구조만 활용, 특성 반영 불가
Node2Vec	전역 구조 학습, 임베딩 재사용 가능	학습 시간 길, 하이퍼파라미터 민감
GCN	다중 hop 이웃 정보 집계, 구조+특성 동시 학습	대규모 그래프에서 메모리 소모 큼

6.3 한계점

본 연구는 노드 특성 부재로 Facebook 데이터에 사용자 속성 정보가 없어 차수만 활용했다. 실제 SNS에서는 프로필, 게시물 텍스트 등을 추가 특성으로 사용 가능할 것이다. 또한 시간 정보가 반영되지 않았다. 링크 형성의 시간적 순서를 고려하지 않았기에 미래 예측을 위해서는 시간 기반 분할이 더 현실적일 것이다. Negative Sampling의 한계로 무작위 음성 샘플은 실제 "거의 연결될 뻔한" 쌍을 포함하지 않아 난이도가 상대적으로 낮다.

6.4 향후 개선 방향

- 본 연구에서는 노드 특성은 차수(1개)였지만, 커뮤니티 탐지로 추출한 정보를 추가 특성으로 GCN에 입력
- 다른 GNN 방식(GraphSAGE, GAT, SEAL 등) 비교
- 양성 샘플과 구조적으로 유사한 음성 샘플을 사용하는 Hard Negative Mining로 변별력 향상 기대
- 다른 데이터셋과의 성능 비교로 방법론의 일반화 가능성 검증

7. 참고문헌

- [1] Grover, A., & Leskovec, J. (2016). node2vec: Scalable feature learning for networks. KDD.
- [2] Kipf, T. N., & Welling, M. (2016). Semi-supervised classification with graph convolutional networks. ICLR 2017.

- [3] Adamic, L. A., & Adar, E. (2003). Friends and neighbors on the Web. *Social Networks*, 25(3).
- [4] Leskovec, J., & Mcauley, J. (2012). Learning to discover social circles in ego networks. *NeurIPS*.
- [5] Stanford SNAP – Facebook Social Circles: <https://snap.stanford.edu/data/ego-Facebook.html>
- [6] eliorc/node2vec GitHub: <https://github.com/eliorc/node2vec>
- [7] PyTorch Geometric Documentation: <https://pytorch-geometric.readthedocs.io/>